Mini-projet de Data Mining appliqué aux données biomédicales

Détection automatique des crises d'absence à partir de signaux EEG

Niveau : Élèves ingénieurs – Data Mining

Compétences :

Data Mining : obligatoire
Python : intermédiaire
Machine Learning : notions de base
Traitement du signal : notions simples à acquérir

Travail : Binôme

Durée : 6 à 8 heures

1. Contexte

L'électroencéphalogramme (EEG) permet d'enregistrer l'activité électrique du cerveau à l'aide d'électrodes placées sur le cuir chevelu. Dans ce TP, nous nous intéressons à la **détection automatique des crises d'absence** à partir de signaux EEG.

Un enregistrement EEG peut contenir plusieurs épisodes de crise. Chaque crise est caractérisée par :

- un instant de début ;
- un instant de fin ;
- une durée.

L'objectif est de construire une chaîne complète de **Data Mining** permettant de passer du signal EEG brut à un modèle capable de détecter automatiquement les périodes correspondant à une crise.

2. Objectifs pédagogiques

À la fin de ce TP, l'étudiant devra être capable de :

- manipuler des données EEG sous forme de fichiers Excel ;
- visualiser les résultats obtenus ;
- segmenter un signal en fenêtres ;
- construire des variables/features à partir d'un signal ;
- constituer un jeu de données pour le Machine Learning ;
- appliquer des algorithmes de classification ;
- comparer les performances de plusieurs modèles ;

- interpréter une matrice de confusion ;
- discuter les limites d'un modèle de détection de crises ;
- reconstruire les périodes de crise à partir des prédictions du modèle.

3. Données fournies

Chaque groupe dispose de plusieurs fichiers EEG.

Chaque fichier correspond à un enregistrement de plusieurs minutes.

Les fichiers contiennent plusieurs canaux on dispose des informations suivantes :

Colonne	Description
Time	Temps en secondes.
EEG canal 1	Amplitude du signal EEG enregistrée sur le canal 1.
EEG canal 2	Amplitude du signal EEG enregistrée sur le canal 2.
...	...
EEG canal N	Amplitude du signal EEG enregistrée sur le canal N.

4. Partie I – Compréhension et exploration des données

Question 1

Charger un fichier EEG à l'aide de Python.

Identifier :

- le nombre de lignes ;
- le nombre de variables ;
- la fréquence d'échantillonnage ;
- la durée totale de l'enregistrement ;
- le nombre de valeurs manquantes

Afficher et visualiser les premières lignes du fichier.

Question 2

Représenter graphiquement le signal EEG en fonction du temps.

Le graphique devra comporter :

- l'axe horizontal : temps en secondes ;

- l'axe vertical : amplitude EEG ;
- un titre ;
- les unités lorsque celles-ci sont disponibles.

Question

Que remarquez-vous visuellement dans les périodes correspondant aux crises ?

5. Partie II – Exploitation des annotations

Les annotations dans le fichier Excel Annotations.xlsx indiquent les instants de début et de fin des crises. Un même enregistrement peut contenir **plusieurs crises**.

Question 3

Identifier automatiquement :

- le début de chaque crise ;
- la fin de chaque crise ;
- le nombre total de crises.

Présenter les résultats sous la forme :

Crise	Début (s)	Fin (s)	Durée (s)
1	...	...	...
2	...	...	...
3	...	...	...

Question 4

Calculer :

- la durée moyenne des crises ;
- la durée minimale ;
- la durée maximale ;
- l'intervalle moyen entre deux crises.

Question

Les crises ont-elles toutes une durée similaire ?

6. Partie III – Construction de la variable cible

L'objectif est maintenant de transformer le problème en problème de classification.

Pour chaque instant du signal, on souhaite savoir si l'on se trouve :

- hors crise → classe 0
- pendant une crise → classe 1

Question 5

Créer une nouvelle colonne :

Class

avec :

0 → absence de crise

1 → crise

Pour chaque échantillon, déterminer sa classe à partir des intervalles :

[début crise, fin crise]

Question 6

Afficher le signal EEG en distinguant visuellement les périodes :

- hors crise ;
- pendant crise.

Question

Le déséquilibre entre les deux classes est-il important ?

Calculer le pourcentage d'échantillons appartenant à chaque classe.

7. Partie IV – Segmentation du signal

Travailler directement sur chaque échantillon n'est pas recommandé pour l'extraction de caractéristiques.

Le signal doit donc être découpé en **fenêtres temporelles**.

Utiliser par exemple :

Fenêtre = 2 secondes

avec un recouvrement de :

50 %

Si la fréquence d'échantillonnage est de 256 Hz :

2 secondes = 512 échantillons

Question 7

Découper le signal en fenêtres.

Pour chaque fenêtre, déterminer sa classe :

- 0 si la fenêtre ne contient pas de crise ;
- 1 si elle contient une crise.

Pour simplifier, une fenêtre sera considérée comme appartenant à la classe 1 si **au moins 50 % de ses échantillons** correspondent à une crise.

Créer un nouveau dataset où :

une ligne = une fenêtre EEG.

8. Partie V – Extraction des caractéristiques

À partir de chaque fenêtre EEG, calculer plusieurs caractéristiques.

Caractéristiques temporelles

Pour chaque fenêtre, calculer :

1. moyenne ;
2. écart-type ;
3. variance ;
4. minimum ;
5. maximum ;
6. amplitude ;
7. RMS ;
8. énergie.

Le dataset final pourra avoir la structure suivante :

Window	Mean	Std	Variance	Min	Max	RMS	Energy	Class
1	...	...	...	...	...	...	...	0
2	...	...	...	...	...	...	...	0
3	...	...	...	...	...	...	...	1
...	...	...	...	...	...	...	...	...

Question 8

Produire ce nouveau dataset à partir des signaux EEG.

Vérifier :

- le nombre total de fenêtres ;
- le nombre de fenêtres de classe 0 ;
- le nombre de fenêtres de classe 1.

9. Partie VI – Analyse fréquentielle

L'EEG contient également des informations dans le domaine fréquentiel.

Pour chaque fenêtre, calculer la transformée de Fourier rapide (FFT).

Représenter :

- le signal dans le domaine temporel ;
- son spectre fréquentiel.

Question 9

Calculer la puissance du signal dans différentes bandes de fréquence.

On pourra considérer, à titre pédagogique :

Bande	Fréquence
Delta	0.5–4 Hz
Theta	4–8 Hz
Alpha	8–13 Hz
Beta	13–30 Hz

Calculer pour chaque fenêtre :

- puissance Delta ;
- puissance Theta ;
- puissance Alpha ;
- puissance Beta.

Ajouter ces variables au dataset.

10. Partie VII – Analyse exploratoire

Avant d'entraîner les modèles, analyser les caractéristiques obtenues.

Question 10

Comparer les caractéristiques entre les deux classes.

Par exemple :

- moyenne de l'énergie pour la classe 0 et la classe 1 ;
- moyenne de la puissance Delta ;
- moyenne de la puissance Theta ;
- écart-type.

Représenter graphiquement les différences observées.

Question 11

Calculer la matrice de corrélation entre les différentes caractéristiques.

Questions

1. Quelles caractéristiques semblent fortement corrélées ?
2. Certaines caractéristiques apportent-elles des informations redondantes ?
3. Quelles caractéristiques semblent les plus discriminantes ?

11. Partie VIII – Construction du modèle de Data Mining

Séparer les données en :

- **80 % : entraînement**
- **20 % : test**

Effectuer la séparation de manière stratifiée afin de conserver approximativement la même proportion des classes.

Question 12

Construire au minimum les modèles suivants :

Modèle 1 – Decision Tree

Entraîner un arbre de décision.

Modèle 2 – Random Forest

Entraîner une forêt aléatoire.

Modèle 3 – K-Nearest Neighbors

Entraîner un modèle KNN.

Modèle 4 – SVM

Entraîner un Support Vector Machine.

12. Partie IX – Évaluation des modèles

Pour chaque modèle, calculer :

- Accuracy ;
- Precision ;
- Recall ;
- F1-score.

Construire également la matrice de confusion.

Présenter les résultats dans un tableau :

Modèle	Accuracy	Precision	Recall	F1-score
Decision Tree	...	...	...	...
Random Forest	...	...	...	...
KNN	...	...	...	...
SVM	...	...	...	...

13. Question importante – Quelle métrique privilégier ?

Dans une application de détection de crises, une simple Accuracy élevée ne signifie pas nécessairement que le modèle est bon.

Supposons que :

95 % des fenêtres = absence de crise

5 % des fenêtres = crise

Un modèle qui prédit toujours :

absence de crise

obtiendrait déjà 95 % d'Accuracy.

Question 13

Expliquer pourquoi l'Accuracy seule peut être trompeuse dans ce problème.

Entre :

- Accuracy ;
- Precision ;

- Recall ;
- F1-score ;

quelle(s) métrique(s) vous semble(nt) la/les plus pertinente(s) pour détecter les crises ?

Justifier votre réponse.

14. Partie X – Détection temporelle des crises

Jusqu'à présent, le modèle prédit une classe pour chaque fenêtre.

Nous allons maintenant reconstruire les crises dans le temps.

Pour chaque fenêtre de test, le modèle doit produire :

0 → pas de crise

1 → crise

Représenter graphiquement :

- le signal EEG ;
- les périodes de crise réelles ;
- les périodes de crise prédites par le modèle.

Question 14

À partir des prédictions du meilleur modèle, reconstruire les intervalles temporels correspondant aux crises détectées.

Exemple :

Crise détectée 1 : 83.5 s → 97.0 s

Crise détectée 2 : 211.0 s → 223.5 s

Crise détectée 3 : 350.0 s → 364.0 s

Comparer ces intervalles avec les annotations réelles.

15. Partie XI – Analyse des erreurs

Analyser les erreurs produites par le meilleur modèle.

Identifier :

- les faux positifs ;
- les faux négatifs ;
- les vrais positifs ;

- les vrais négatifs.

16. Partie XII – Amélioration du système

Proposer au moins **deux améliorations** permettant d'obtenir de meilleures performances.

Quelques pistes possibles :

- modifier la taille des fenêtres ;
- modifier le recouvrement ;
- ajouter de nouvelles caractéristiques ;
- sélectionner les caractéristiques les plus pertinentes ;
- normaliser les données ;
- modifier les hyperparamètres ;
- utiliser une autre méthode de classification ;
- Utiliser le deep learning
- traiter le déséquilibre des classes.

18. Travail demandé

Chaque binôme devra fournir :

1. Notebook Python

Le notebook devra contenir :

- chargement des données ;
- exploration ;
- visualisations ;
- traitement des annotations ;
- segmentation ;
- extraction des caractéristiques ;
- entraînement des modèles ;
- évaluation ;
- comparaison ;
- détection temporelle ;
- analyse des erreurs.

2. Rapport

Le rapport devra contenir :

Introduction

Présentation du problème.

Méthodologie

Description du pipeline réalisé.

Résultats

Résultats obtenus avec les différents modèles.

Discussion

Analyse des performances et des erreurs.

Conclusion

Bilan du travail et limites.

19. Pipeline attendu

Le pipeline global du projet est :

SIGNAL EEG

|

▼

Exploration des données

|

▼

Prétraitement

|

▼

Segmentation

|

▼

Extraction des features

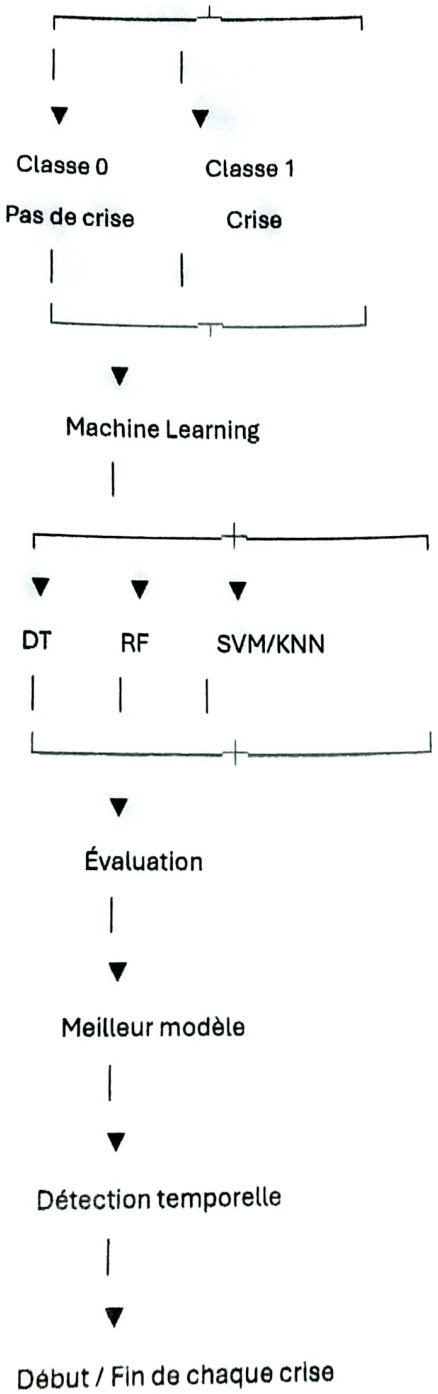
|

▼

Dataset de classification

|

▼


Classe 0
Classe 1
Pas de crise
Crise
Machine Learning
DT
RF
SVM/KNN
Évaluation
Meilleur modèle
Détection temporelle
Début / Fin de chaque crise